

**Informe Análisis de Datos Económicos y Financieros para Predecir el Tipo
de Cambio EUR/USD**

Simón Patiño, Isabella Guerrero

Universidad EIA

Trabajo Final

Informe Análisis de Datos Económicos y Financieros para Predecir el Tipo de Cambio EUR/USD

Introducción:

El objetivo de este estudio es predecir el tipo de cambio EUR/USD utilizando datos económicos y financieros. Se han utilizado diversos conjuntos de datos intradía de Dukascopy y MQL5, los cuales incluyen indicadores macroeconómicos tanto de Estados Unidos como de Europa.

Obtención de Datos:

Se uso como archivo principal el Dataset del EUR/USD con intervalos de una hora de la Dukascopy (<https://www.dukascopy.com/swiss/spanish/home/>), donde se obtuvieron los datos de Open, High Low Close y Volume, dado el mundo de la divisas es complejo y depende de mucho factores, estos datos eran insuficientes para un modelo preciso y confiable, por lo que se complementó con los datos macro económicos que afectan a la economía de EEUU y a la zona Euro, estos datos se obtuvieron del Dataset de MQL5 (<https://www.mql5.com/es/economic-calendar>).

- **Datos de Mercado**
 - Tipo de cambio diario EUR/USD intradía.
- **Indicadores Macroeconómicos de Estados Unidos**
 - Producto Interno Bruto (PIB) trimestral.
 - Decisiones de tasas de interés de la Reserva Federal.
 - Índice de manufactura del ISM.
 - Cambios en los inventarios de petróleo crudo.
 - Cambio en el empleo no agrícola de ADP.
 - Pedidos de bienes duraderos excluyendo transporte.
 - Índice de confianza del consumidor.
 - Permisos de construcción.
 - Ventas de viviendas existentes y nuevas.
- **Indicadores Macroeconómicos de Europa y Alemania**
 - Cambio en el empleo de la Unión Europea.
 - Índice de precios al productor (IPP) de Alemania.

Informe Análisis de Datos Económicos y Financieros para Predecir el Tipo de Cambio EUR/USD

- PIB trimestral de la Unión Europea y Alemania.
- Indicador de sentimiento económico ZEW de Alemania.
- Saldo comercial de España y la Unión Europea.
- Subastas de bonos a 10 años de Alemania.

Creación del DataSet Combinado:

Como se disponía de diferentes data set, se procedió a realizar un código donde cada archivo CVS, tuvieran la misma estructura de datos y de esta forma poderlos combinar, como los datos macroeconómicos se dan en fechas fijas, se rellenó los días posteriores a la fecha de publicación con el valor del indicador hasta su próximo informe y de esta manera se tenía en cuenta su influencia en un periodo de tiempo.

El código en Python realiza varias operaciones para combinar múltiples conjuntos de datos en un DataFrame utilizando la biblioteca Pandas:

Importación de bibliotecas:

- Se importa Pandas como pd.
- Se importa el módulo os para manejar operaciones relacionadas con el sistema operativo.

Carga de datos:

- Cada conjunto de datos se carga desde archivos CSV utilizando pd.read_csv().
- Los archivos se cargan utilizando rutas relativas y se combinan con el directorio actual y una carpeta llamada 'Datos'.
- Los datos se separan utilizando '\t' como delimitador.

Informe Análisis de Datos Económicos y Financieros para Predecir el Tipo de Cambio EUR/USD

Procesamiento de datos:

Para cada conjunto de datos:

- Se separa una columna que contiene múltiples valores en columnas individuales.
- La columna de fecha se formatea como un objeto de fecha utilizando `pd.to_datetime()`.
- Se eliminan las columnas originales que contenían los datos combinados.

Unión de datos:

- Los datos se unen en un solo DataFrame utilizando la columna de fecha como clave de unión.
- Se utiliza el método `pd.merge()` para unir los DataFrames.
- Se utiliza el argumento `how='left'` para mantener todas las filas del segundo y tercer conjunto de datos.

Relleno de valores faltantes:

- Se rellenan los valores faltantes (NaN) utilizando los valores de las filas anteriores que contienen datos.

Eliminación de filas iniciales consecutivas con NaN:

- Se eliminan las filas iniciales consecutivas donde hay valores NaN en columnas específicas utilizando `dropna()`.

Guardado del archivo combinado:

- El DataFrame combinado se guarda como un archivo CSV en la ruta especificada utilizando `to_csv()`.
- El parámetro `index=False` se utiliza para evitar que se agregue el índice del DataFrame al archivo CSV.

Impresión de mensaje de éxito y visualización de los datos combinados:

Informe Análisis de Datos Económicos y Financieros para Predecir el Tipo de Cambio EUR/USD

- Se imprime un mensaje indicando que el archivo combinado se ha guardado con éxito.
- Se imprime el DataFrame combinado.

En resumen, el código carga múltiples conjuntos de datos, los combina en un solo DataFrame, realiza algunas operaciones de limpieza y procesamiento de datos, y finalmente guarda el resultado combinado en un archivo CSV.

Se realizó una exploración de los datos, en busca de datos atípicos, posteriormente se eliminaron los datos faltantes, duplicados o irrelevantes, buscando estandarizar la estructura de datos.

Algoritmos predictivos

Se escogieron estos dos tipos de red de predictiva, óptimas para Series temporales:

Red LSTM (Long Short-Term Memory):

Descripción: Una red LSTM es un tipo de red neuronal recurrente (RNN) especializada en modelar secuencias de datos y es especialmente útil cuando se trabaja con datos secuenciales como texto, audio, series temporales, etc. La principal ventaja de las LSTMs sobre las RNN tradicionales radica en su capacidad para aprender y recordar dependencias a largo plazo en los datos de secuencia.

Características clave:

- Capacidad para mantener y actualizar estados de memoria a largo plazo.
- Utiliza compuertas (gate) para controlar el flujo de información.
- Resuelve el problema de desvanecimiento del gradiente, lo que permite un aprendizaje más efectivo en secuencias largas.
- Ideal para modelar secuencias largas y capturar relaciones temporales complejas.

Aplicaciones:

- Series temporales: Predicción de valores futuros en series temporales financieras, meteorológicas, etc.

Informe Análisis de Datos Económicos y Financieros para Predecir el Tipo de Cambio EUR/USD

Red CNN (Convolutional Neural Network):

Descripción: Una red CNN es un tipo de red neuronal diseñada principalmente para procesar datos con una estructura de cuadrícula, como imágenes. Se destacan por su capacidad para capturar patrones locales y espaciales en los datos mediante el uso de filtros convolucionales, lo que las hace especialmente poderosas en tareas de visión por computadora.

Características clave:

- Utiliza capas convolucionales para extraer características locales de los datos de entrada.
- Incorpora capas de agrupamiento (pooling) para reducir la dimensionalidad y preservar características importantes.
- Son invariantes a la traslación, lo que significa que pueden identificar características independientemente de su ubicación en la imagen.
- Son altamente eficientes en términos de parámetros y son capaces de aprender representaciones jerárquicas de los datos.

Aplicaciones:

- Series temporales: Predicción de valores futuros en series temporales financieras, meteorológicas, etc.

Se procedió a realizar los códigos teniendo en cuenta esto:

La normalización de datos, tanto a los datos de entrada como de salida.

La busca de mejor Hiperparametros usando RandomizedSearchCV.

En los primeros modelos se presentaron sobreajuste (overfitting), en los datos para lo que se aplicaron técnicas para evitarlo, tales como:

- **Regularización:** La regularización es una técnica común para evitar el sobreajuste. Puedes aplicar regularización L1 o L2 a los pesos de la red neuronal. En tu código, ya has utilizado regularización L2 en las capas LSTM mediante el parámetro `kernel_regularizer=L2(0.001)`.
- **Parada Temprana (Early Stopping):** La parada temprana es una técnica útil para detener el entrenamiento cuando la pérdida en el conjunto de validación deja de

Informe Análisis de Datos Económicos y Financieros para Predecir el Tipo de Cambio EUR/USD

disminuir, lo que indica que el modelo está empezando a sobreajustarse. Esto se implementa utilizando la clase EarlyStopping de Keras, como lo has hecho en tu código.

- **Validación Cruzada:** La validación cruzada es una técnica para evaluar el rendimiento del modelo en múltiples particiones de los datos. Esto puede ayudar a obtener una estimación más robusta del rendimiento del modelo y a reducir el riesgo de sobreajuste.
- **Se realizaron gráficos para validar la curva de aprendizaje.**

Descripción del código de la Red LSTM:

- **Importaciones de bibliotecas:** Se importan las bibliotecas necesarias, incluyendo NumPy para operaciones numéricas, Pandas para trabajar con datos en forma de DataFrames, Matplotlib para visualizaciones, y las funciones y clases necesarias de TensorFlow y scikit-learn para el modelado y la evaluación.
- **Carga de datos:** Se carga un archivo CSV que contiene los datos financieros. La ruta del archivo se especifica de forma relativa y se verifica si el archivo existe en la ubicación esperada.
- **Preprocesamiento de datos:** Los datos se dividen en conjuntos de entrenamiento y prueba, y se escalan utilizando MinMaxScaler para asegurar que todas las características estén en el rango [0, 1].
- **Creación de conjuntos de datos:** Se define una función para crear conjuntos de datos de entrada y salida para el modelo LSTM. Cada entrada consiste en una secuencia de pasos temporales, y la salida es el siguiente paso temporal después de esa secuencia.
- **Definición y entrenamiento del modelo LSTM:** Se crea un modelo LSTM utilizando la API Sequential de Keras. El modelo tiene dos capas LSTM y una capa densa para predecir tanto el precio de apertura como el de cierre. El modelo se compila con el optimizador Adam y la pérdida se mide utilizando el error cuadrático medio.
- **Evaluación del modelo:** Se evalúa el modelo en los conjuntos de entrenamiento y prueba utilizando métricas como el error cuadrático medio (MSE), el error absoluto medio (MAE) y la puntuación R2.
- **Predicciones y visualización:** Se realizan predicciones para el próximo valor y para las últimas ventanas de datos. También se visualizan las predicciones junto con los valores reales utilizando Matplotlib.

Informe Análisis de Datos Económicos y Financieros para Predecir el Tipo de Cambio EUR/USD

- Desfase y ajuste de predicciones: Se calcula y aplica un desfase utilizando una media móvil a las predicciones para mejorar su precisión.

Resultados de la Red LSTM:

Métricas de entrenamiento:

Error Cuadrático Medio (MSE): 0.000401805279963297

Error Absoluto Medio (MAE): 0.014853694678063249

Puntuación R2: 0.9932396902813184

29/29 ————— 0s 6ms/step

Métricas de prueba:

Error Cuadrático Medio (MSE): 0.000320559766340041

Error Absoluto Medio (MAE): 0.012757990318731743

Puntuación R2: 0.975940506999281

1/1 ————— 0s 20ms/step

Métricas de Entrenamiento:


1. Error Cuadrático Medio (MSE): Con un valor de 0.000401, el MSE indica que, en promedio, los cuadrados de los errores de predicción en el conjunto de entrenamiento son relativamente bajos. Esto sugiere que el modelo tiene un buen ajuste a los datos de entrenamiento.
2. Error Absoluto Medio (MAE): Con un MAE de 0.014, las predicciones tienden a desviarse en promedio por 0.014 unidades de la variable objetivo en el conjunto de entrenamiento. Esto indica que, en promedio, las predicciones tienen un margen de error aceptable.
3. Puntuación R2: Con un valor de 0.993, el coeficiente de determinación sugiere que el modelo explica aproximadamente el 99.3% de la variabilidad en los datos de entrenamiento. Esto indica un ajuste muy bueno del modelo a los datos de entrenamiento.

Informe Análisis de Datos Económicos y Financieros para Predecir el Tipo de Cambio EUR/USD

Métricas de Prueba:

1. Error Cuadrático Medio (MSE): El MSE en el conjunto de prueba es 0.000321, lo que sugiere que las predicciones tienen errores cuadráticos relativamente bajos en comparación con los valores reales. Esto indica un buen rendimiento del modelo en el conjunto de prueba.
2. Error Absoluto Medio (MAE): Con un MAE de 0.013, las predicciones tienden a desviarse en promedio por 0.013 unidades de la variable objetivo en el conjunto de prueba. Esto indica que las predicciones del modelo tienen un margen de error aceptable en el conjunto de prueba.
3. Puntuación R2: Con un valor de 0.976 en el conjunto de prueba, el modelo explica aproximadamente el 97.6% de la variabilidad en los datos de prueba. Aunque ligeramente más bajo que en el conjunto de entrenamiento, este sigue siendo un buen indicador de ajuste del modelo a los datos de prueba.

En general, las métricas tanto en el conjunto de entrenamiento como en el de prueba muestran que el modelo tiene un buen rendimiento y se ajusta bien a los datos, aunque puede haber una ligera disminución en el rendimiento cuando se aplica a datos nuevos en comparación con los datos de entrenamiento.



Informe Análisis de Datos Económicos y Financieros para Predecir el Tipo de Cambio EUR/USD

Análisis de sobreajuste

Para evaluar el sobreajuste, es crucial comparar las métricas de entrenamiento con las de prueba. Aquí hay algunas señales que podrían indicar sobreajuste en tu modelo:

1. **Diferencia significativa entre métricas de entrenamiento y prueba:** Si las métricas de entrenamiento son considerablemente mejores que las de prueba, esto sugiere que el modelo está memorizando los datos de entrenamiento en lugar de aprender patrones generales.
2. **Diferencia entre MSE y R2:** Si el MSE de entrenamiento es muy bajo pero el R2 de prueba es significativamente más bajo, esto podría indicar que el modelo está sobreajustando los datos y no generalizando bien.
3. **Comparación de MAE y MSE:** Si el MAE es bajo en comparación con el MSE en el conjunto de prueba, podría indicar que el modelo está sobreajustando los datos, ya que el MAE es menos sensible a los valores atípicos que el MSE.
4. **Visualización de curvas de aprendizaje:** Graficar las curvas de aprendizaje (error en función del tamaño del conjunto de entrenamiento) puede proporcionar una imagen clara de si el modelo está sobreajustando. Si el error en el conjunto de entrenamiento sigue disminuyendo mientras que el error en el conjunto de prueba se estanca o incluso aumenta, es una señal clara de sobreajuste.

En tu caso, dado que las métricas de prueba son comparativamente buenas y están muy cerca de las métricas de entrenamiento, no parece que haya un sobreajuste significativo. Las métricas de prueba están en línea con las de entrenamiento, lo que sugiere que el modelo generaliza bien a datos nuevos.

Informe Análisis de Datos Económicos y Financieros para Predecir el Tipo de Cambio EUR/USD

Descripción del código de la Red CNN:

- **Importación de bibliotecas:** Se importan las bibliotecas necesarias para el análisis de datos y el entrenamiento del modelo, incluyendo NumPy, Pandas, Matplotlib y las funciones relacionadas con el aprendizaje automático de la biblioteca TensorFlow.
- **Carga de datos:** Se carga un conjunto de datos desde un archivo CSV. El código primero verifica si el archivo existe en una ubicación específica y, si es así, carga los datos en un DataFrame de Pandas.
- **Preprocesamiento de datos:** Los datos se dividen en conjuntos de entrenamiento y prueba. Se aplica un escalado Min-Max a las características de interés (en este caso, los precios de apertura y cierre de las acciones).
- **Creación del conjunto de datos:** Se define una función para crear conjuntos de datos en el formato adecuado para el modelado. En este caso, la función divide los datos en ventanas de tiempo y crea pares de entrada y salida para el modelo.
- **Definición del modelo CNN:** Se crea un modelo secuencial de TensorFlow que consta de capas convolucionales 1D, capas de agrupación máxima y capas densas. La arquitectura se configura para trabajar con datos de entrada bidimensionales.
- **Entrenamiento del modelo:** El modelo se compila con una función de pérdida y un optimizador específicos y se entrena utilizando los datos de entrenamiento. Se utiliza la parada temprana para evitar el sobreajuste del modelo.
- **Evaluación del modelo:** Se evalúa el rendimiento del modelo en los conjuntos de datos de entrenamiento y prueba utilizando métricas como el error cuadrático medio (MSE), el error absoluto medio (MAE) y la puntuación R2.
- **Visualización del rendimiento del modelo:** Se traza la curva de aprendizaje del modelo para visualizar cómo la pérdida cambia durante el entrenamiento.
- **Predicciones y visualización:** Se realizan predicciones utilizando el modelo entrenado en los datos de prueba y se comparan con los valores reales.
- Se muestra un gráfico que compara las predicciones del modelo con los valores reales de cierre de las acciones.

Informe Análisis de Datos Económicos y Financieros para Predecir el Tipo de Cambio EUR/USD

- **Ajuste de predicciones:** Se calcula y aplica un desfase utilizando una media móvil para ajustar las predicciones del modelo.
- **Presentación de las predicciones finales:** Se muestran las últimas dos predicciones del modelo CNN para los precios de apertura y cierre de las acciones.

Resultados de las Métricas Red CNN:

Métricas de entrenamiento:

Error Cuadrático Medio (MSE): 0.00021932806178243306

Error Absoluto Medio (MAE): 0.01049387739417965

Puntuación R2: 0.9962372515225255

Métricas de prueba:

Error Cuadrático Medio (MSE): 0.00015059765588898118

Error Absoluto Medio (MAE): 0.008433869076801666

Puntuación R2: 0.9897327249675614

Análisis de las métricas:

Métricas de Entrenamiento:

- **Error Cuadrático Medio (MSE):** Es la media de los errores al cuadrado entre los valores predichos por el modelo y los valores reales en el conjunto de datos de entrenamiento. En este caso, el MSE es 0.000219, lo que indica que, en promedio, los cuadrados de los errores de predicción son muy pequeños en el conjunto de entrenamiento, lo que sugiere un buen ajuste del modelo.
- **Error Absoluto Medio (MAE):** Es la media de las diferencias absolutas entre los valores predichos y los valores reales en el conjunto de datos de entrenamiento. Con un MAE de 0.010, parece que las predicciones tienden a desviarse en promedio por 0.010 unidades de la variable objetivo.
- **Puntuación R2:** También conocido como coeficiente de determinación, es una medida de cuán bien el modelo se ajusta a los datos. Varía entre 0 y 1, donde 1 indica un ajuste perfecto. Con un valor de 0.996, el modelo explica aproximadamente el 99.6% de la


Informe Análisis de Datos Económicos y Financieros para Predecir el Tipo de Cambio EUR/USD

variabilidad en los datos de entrenamiento, lo que sugiere un ajuste extremadamente bueno.

Métricas de Prueba:

- **Error Cuadrático Medio (MSE):** Similar al MSE de entrenamiento, mide la media de los errores al cuadrado entre las predicciones y los valores reales, pero en el conjunto de datos de prueba. Un MSE de 0.000150 indica que el modelo también tiene un buen rendimiento en el conjunto de prueba.
- **Error Absoluto Medio (MAE):** Al igual que el MAE de entrenamiento, mide la media de las diferencias absolutas entre las predicciones y los valores reales, pero en el conjunto de datos de prueba. Con un MAE de 0.008, las predicciones tienden a desviarse en promedio por 0.008 unidades de la variable objetivo en el conjunto de prueba.
- **Puntuación R2:** Al igual que en el conjunto de entrenamiento, indica cuán bien el modelo se ajusta a los datos de prueba. Un valor de 0.989 sugiere que el modelo explica aproximadamente el 98.9% de la variabilidad en los datos de prueba, lo que también indica un ajuste muy bueno.

En resumen, todas las métricas tanto en el conjunto de entrenamiento como en el de prueba muestran que el modelo tiene un rendimiento excelente y se ajusta muy bien a los datos.



Informe Análisis de Datos Económicos y Financieros para Predecir el Tipo de Cambio EUR/USD

Análisis de sobreajuste:

Para evaluar si hay sobreajuste en un modelo de regresión, se compara el rendimiento en los datos de entrenamiento con el rendimiento en los datos de prueba:

Entrenamiento:

- MSE: 0.0002193
- MAE: 0.01049
- R2: 0.9962

Prueba:

- MSE: 0.0001506
- MAE: 0.00843
- R2: 0.9897

En general, cuando el rendimiento en los datos de entrenamiento es significativamente mejor que en los datos de prueba, existe la posibilidad de sobreajuste. Sin embargo, en este caso, las métricas de rendimiento en los datos de prueba son muy similares a las métricas de entrenamiento. Esto sugiere que el modelo generaliza bien y no parece estar sobreajustado.

El ligero desajuste que se observa (por ejemplo, el MSE y MAE son ligeramente más altos en los datos de prueba en comparación con los datos de entrenamiento) es típico y esperado. En general, estas diferencias son pequeñas y sugieren que el modelo se desempeña de manera consistente en datos nuevos.

Con los dos modelos definitivos se procedió con su comparación:

Se usó un nuevo código que integrara los dos anteriores con unas métricas de coeficiente de determinación (R2), ICC y CCC y de esta forma determinar cuál es el mejor:

Informe Análisis de Datos Económicos y Financieros para Predecir el Tipo de Cambio EUR/USD

Descripción detallada del código:

- Importación de bibliotecas: Se importan todas las bibliotecas necesarias, incluyendo numpy, pandas, matplotlib, scikit-learn, TensorFlow y Pingouin (para calcular el coeficiente de correlación de concordancia).
- Carga y Preprocesamiento de Datos:
- Se carga un conjunto de datos financiero desde un archivo CSV.
- Los datos se dividen en conjuntos de entrenamiento y prueba.
- Se escala el conjunto de datos usando MinMaxScaler para que los valores estén en un rango específico (0 a 1).
- Preparación de Datos para Modelos LSTM y CNN: Se crean funciones para formatear los datos en secuencias adecuadas para los modelos LSTM y CNN.
- Los datos se transforman para que sean compatibles con las arquitecturas de estos modelos.
- Definición y Entrenamiento de Modelos: Se define un modelo LSTM con dos capas LSTM seguidas de una capa densa de salida.
- Se define un modelo CNN con capas Conv1D, MaxPooling1D, y capas densas.
- Ambos modelos se compilan con una función de pérdida y un optimizador.
- Se utilizan callbacks de EarlyStopping para detener el entrenamiento si la pérdida de validación deja de mejorar.
- Los modelos se entrenan utilizando los datos de entrenamiento.
- Evaluación de Modelos: Se evalúan los modelos utilizando métricas como el Error Cuadrático Medio (MSE), el Error Absoluto Medio (MAE), el coeficiente de determinación (R2), ICC y CCC.
- Se imprimen las métricas de entrenamiento y prueba para cada modelo.
- Visualización de la Curva de Aprendizaje: Se trazan las curvas de pérdida de entrenamiento y validación para cada modelo.
- Conclusión y Comparación: Se comparan las métricas de rendimiento de los modelos LSTM y CNN.
- Se muestran las últimas predicciones realizadas por cada modelo.

Informe Análisis de Datos Económicos y Financieros para Predecir el Tipo de Cambio EUR/USD

Los resultados del modelo comparativo fueron:

Métricas de prueba CNN:

Error Cuadrático Medio (MSE): 0.00023743925042783

Error Absoluto Medio (MAE): 0.011118714734277843

Puntuación R2: 0.9838139213341798

Confiabilidad entre evaluadores (ICC) LSTM:

ICC Open: 0.994549494632801

ICC Close: 0.9918447152652222

Confiabilidad entre evaluadores (ICC) CNN:

ICC Open: 0.9919391521255835

ICC Close: 0.9908171037814456

Últimas dos predicciones LSTM (Open, Close):

Predicción 1: Open = 0.07415733486413956, Close = 0.07618195563554764

Predicción 2: Open = 0.07131119817495346, Close = 0.07318568229675293

Últimas dos predicciones CNN (Open, Close):

Predicción 1: Open = 0.07414592802524567, Close = 0.07541470974683762

Predicción 2: Open = 0.07145023345947266, Close = 0.07281443476676941

Concordancia LSTM:

CCC Open: 0.9937229674715

CCC Close: 0.9909965634517546

Concordancia CNN:

CCC Open: 0.9918948546808908

CCC Close: 0.9907400872418395

Informe Análisis de Datos Económicos y Financieros para Predecir el Tipo de Cambio EUR/USD

interpretación de la cada métrica:

Para la CNN:


- **Error Cuadrático Medio (MSE):** Este valor (0.00023743925042783) indica la magnitud promedio del error al cuadrado entre las predicciones y los valores reales. Un MSE cercano a cero sugiere que las predicciones están muy cerca de los valores reales.
- **Error Absoluto Medio (MAE):** El MAE (0.011118714734277843) proporciona la magnitud promedio de los errores en las predicciones, sin considerar su dirección. Un MAE bajo indica que las predicciones son bastante precisas en términos absolutos.
- **Puntuación R2:** La R2 (0.9838139213341798) indica la proporción de la varianza en la variable dependiente que es predecible a partir de las variables independientes en el modelo. Una puntuación R2 cercana a 1 sugiere un buen ajuste del modelo a los datos.
- **Confiabilidad entre evaluadores (ICC) para la CNN:** Los valores ICC (0.9919391521255835 para Open y 0.9908171037814456 para Close) indican la fiabilidad o consistencia de las predicciones entre diferentes evaluadores o en diferentes condiciones. Valores cercanos a 1 sugieren una alta concordancia entre las predicciones.
- **Últimas dos predicciones CNN:** Estas son las dos predicciones más recientes del modelo CNN para las variables "Open" y "Close" en algún tipo de serie temporal. Proporcionan una idea de cómo el modelo está haciendo predicciones en el momento actual.
- **Concordancia (CCC) para la CNN:** Los valores CCC (0.9918948546808908 para Open y 0.9907400872418395 para Close) son métricas de concordancia que evalúan qué tan bien las clasificaciones de los diferentes evaluadores se alinean. Valores cercanos a 1 indican una alta concordancia.

Para la LSTM:

- **Últimas dos predicciones LSTM:** Similar a las predicciones de la CNN, estas son las dos predicciones más recientes del modelo LSTM para las variables "Open" y "Close".
- **Concordancia (CCC) para la LSTM:** Estas métricas indican la concordancia entre las clasificaciones de diferentes evaluadores para el modelo LSTM. Valores cercanos a 1 sugieren una alta concordancia entre las predicciones.

Informe Análisis de Datos Económicos y Financieros para Predecir el Tipo de Cambio EUR/USD

En resumen, ambas CNN y LSTM parecen estar realizando bien en la tarea de predicción, con valores de error bajos, altos valores de R2 y altos niveles de concordancia entre las predicciones.



¿Cuál es mejor Modelo?:

Para evaluar cuál modelo es mejor según las métricas proporcionadas, primero debemos considerar la importancia relativa de cada métrica en relación con el problema específico que estás abordando. Sin embargo, basándonos únicamente en las métricas proporcionadas, podemos hacer algunas observaciones:

- **MSE y MAE:** Ambos modelos tienen valores muy bajos de Error Cuadrático Medio (MSE) y Error Absoluto Medio (MAE), lo que sugiere que ambos modelos están haciendo predicciones muy precisas en términos de la magnitud de los errores. No hay una diferencia notable en este aspecto entre la CNN y la LSTM.
- **Puntuación R2:** Ambos modelos tienen puntuaciones R2 muy altas, lo que indica que son capaces de explicar la mayoría de la variabilidad en los datos de destino. Sin

Informe Análisis de Datos Económicos y Financieros para Predecir el Tipo de Cambio EUR/USD

embargo, la CNN tiene una puntuación ligeramente más alta que la LSTM en este aspecto.

- **Confiabilidad entre evaluadores (ICC):** Tanto la CNN como la LSTM tienen valores altos de ICC para ambas variables "Open" y "Close". No hay una diferencia sustancial entre los modelos en términos de confiabilidad entre evaluadores.
- **Concordancia (CCC):** Ambos modelos tienen valores altos de CCC para ambas variables "Open" y "Close". Al igual que con ICC, no hay una diferencia significativa entre los modelos en términos de concordancia.

Dado que las métricas son comparables entre los dos modelos y no hay una diferencia clara en el rendimiento en función de las métricas proporcionadas, la elección entre la CNN y la LSTM puede depender de otros factores, como la interpretabilidad del modelo, la eficiencia computacional y la capacidad de generalización a datos nuevos. Te recomendaría considerar estos factores adicionales para tomar una decisión informada sobre cuál modelo usar en tu aplicación específica.

Conclusiones:

De acuerdo con los resultados obtenidos, ambos modelos demostraron un rendimiento sobresaliente, lo que indica que la selección de los datos fue adecuada y que se eligió correctamente el tipo de red neuronal para abordar el problema. Este desempeño positivo sugiere que tanto la preparación de los datos como la arquitectura de la red fueron consideradas de manera óptima para maximizar la efectividad del modelo.

En cuanto a la posibilidad de utilizar estos modelos para predecir el precio futuro del EUR/USD, es prudente ser cauteloso. Aunque los modelos han mostrado un buen rendimiento en las pruebas realizadas, hacer predicciones futuras con ellos directamente sería arriesgado sin una validación adicional. Para poder utilizar estos modelos de manera confiable en la predicción de precios futuros, sería necesario desarrollar códigos adicionales que permitan incorporar datos nuevos y evaluar continuamente la precisión de las predicciones.

Además, es esencial implementar un plan de inversiones utilizando una cuenta Demo antes de arriesgar capital real. Este paso es crucial para evaluar el desempeño del modelo en un entorno controlado y verificar si las predicciones son consistentes con las expectativas. Utilizando una

Informe Análisis de Datos Económicos y Financieros para Predecir el Tipo de Cambio EUR/USD

cuenta Demo, se puede simular la inversión sin riesgos financieros, permitiendo observar cómo se comporta el modelo en condiciones de mercado en tiempo real. Este proceso de validación adicional ayudará a identificar posibles ajustes necesarios y a asegurar que el modelo sea verdaderamente robusto antes de su aplicación en escenarios de inversión reales.

En resumen, aunque los resultados iniciales son prometedores, la transición de pruebas a predicciones reales debe ser gestionada con precaución y mediante una serie de pasos adicionales que garanticen la fiabilidad y consistencia del modelo en el tiempo.

Informe Análisis de Datos Económicos y Financieros para Predecir el Tipo de Cambio EUR/USD

Referencias

Dukascopy. Retrieved from <https://www.dukascopy.com/swiss/spanish/home/>

MQL5. Economic calendar. Retrieved from <https://www.mql5.com/es/economic-calendar>